

Exakt varför fungerar grafassisterad symbolisk regression?

En ren ablationsstudie på samma fysikbenchmark som Lazebnik & Liberzon (2026)

Huvudfråga. Kan förbättringen i grafassisterad symbolic regression kausalt tillskrivas grafstrukturen och message passing - eller kommer en väsentlig del från neural denoising och clean simulated prior knowledge?

Bakgrund och motivation

Lazebnik & Liberzon föreslår en solver-agnostisk dual representation för symbolic regression (SR): kandidatmodeller bedöms både i rå tabulär datarymd och i ett latent rum från en spatio-temporal GNN. GNN:n är en tvålagars GCN som tränas self-supervised på ground-truth simulated data före SR-steget, därefter fryses encodern och återanvänds i experimenten. Studien använder tio fysikbaserade benchmarkekvationer och tio off-the-shelf SR-metoder. [1]

På standardbenchmark rapporteras typiskt små men systematiska förbättringar, omkring 1–3 %. Under ökande observationsbrus rapporteras större robusthetsvinster, med upp till cirka 10–15 % långsammare felökning. Studien rapporterar även bättre dataeffektivitet. [1]

Det centrala metodproblemet är att flera mekanismer förändras samtidigt:

$\underbrace{\text{grafens topologi / message passing}}_A + \underbrace{\text{neural representation / denoising}}_B + \underbrace{\text{clean simulated prior}}_C$

Författarna identifierar själva avsaknaden av jämförelser mot alternativa embeddings, exempelvis autoencoders eller neural operators, som en begränsning och ett viktigt spår för framtida forskning. [1]

Forskningshypotes

H1 - Graph-inductive-bias. En fysiskt korrekt spatio-temporal graf förbättrar equation recovery även när arkitektur, träningsdata och SR-metod hålls konstanta.

H2 - Clean-prior-effekt. En mätbar del av förbättringen kommer från att GNN:n först tränas på rena simulerade trajectories och därefter används på brusiga observationer.

H3 - Denoising snarare än graf. En vanlig neural encoder utan meningsfulla kanter kan ge en betydande del av samma förbättring genom representation learning / smoothing.

H4 - Noise-regim. Grafens verkliga värde framträder främst i high-noise / low-data-regimer, inte på rena och välbestämda data.

Minimal experimentdesign - exakt samma dataset

Utgångspunkten bör vara samma tio benchmarkekvationer, samma genererade features, samma train/test-protokoll och samma brusnivåer som originalstudien. Kod och data anges av författarna som tillgängliga från corresponding author. [1]

ID	Representation	Pretraining	Vad varianten isolerar
T0	Tabulär SR	Ingen	Original baseline.
G1	Dual GCN + SR	Clean ground truth	Reproduktion av huvudmetoden.
G2	Dual GCN + SR	Endast noisy observations	Skillnaden G1-G2 approximerar värdet av clean prior.
A1	Autoencoder/MLP + SR	Clean ground truth	Neural representation/denoising utan graph inductive bias.
G3	GCN med shuffled edges + SR	Clean ground truth	Testar om meningsfull graph topology är viktig, inte bara nätverkets kapacitet.
G4	GCN med identitetsgraf ($A = I$) + SR	Clean ground truth	Isolerar effekten av faktisk message passing.
G5	Directed temporal GNN + SR	Clean eller noisy	Testar om explicit tidsriktning/kauslighet förbättrar den odirected originalgraf.

Kausala kontraster

$$\begin{aligned}\Delta_{\text{clean prior}} &\approx G1 - G2 \\ \Delta_{\text{graph topology}} &\approx G1 - G3 \\ \Delta_{\text{message passing}} &\approx G1 - G4 \\ \Delta_{\text{graph vs neural embedding}} &\approx G1 - A1\end{aligned}$$

Det viktiga är att **endast en komponent ändras per kontrast**. Samma data, samma SR-budget, samma operatorbibliotek och samma evalueringskod ska användas.

Kontroll av symbolic regression

Originalstudien använder flera olika SR-familjer. PySR och gplearn är stokastiska evolutionära metoder; SINDy bygger i stället på sparse regression. [1]

En ren uppföljning kan därför göras i två steg:

1. **Kontrollerad kärna:** börja med SINDy eller annan lågvarians-metod för att minimera brus från själva SR-sökningen.
2. **Stokastisk stresstest:** upprepa sedan med PySR med parade random seeds och identisk search budget mellan T0/G1/G2/A1/G3/G4.

För PySR bör varje seed bilda ett par:

$$\text{seed}_i : \quad SR_{\text{tabular}} \longleftrightarrow SR_{\text{representation}}.$$

Det gör att en liten representationseffekt inte blandas ihop med variation från evolutionär search.

Mätetal och analys

Primärt bör studien mäta **equation recovery**, inte bara prediktionsfel.

- **Exact / symbolic recovery rate:** andel körningar som återfinner en symboliskt ekvivalent governing equation.
- **ETD / strukturell likhet:** samma typ av expression-tree metric som originalstudien, kompletterad med algebraisk förenkling där möjligt.
- **MAE och R^2 :** numerisk kvalitet, för direkt jämförelse med originalpaperet.
- **Robusthetskurva:** recovery rate och fel som funktion av brusnivå.
- **Dataeffektivitet:** minsta K som krävs för en given recovery-nivå.
- **Latent-space diagnostics:** neighborhood compactness och cluster separation, men kopplade direkt till equation recovery.

Nyckelanalys

I stället för att enbart fråga om GNN+SR är bättre än tabulär SR, skattas ett bidrag för varje mekanism:

$$\text{Total gain} \approx \Delta_{\text{clean prior}} + \Delta_{\text{neural smoothing}} + \Delta_{\text{graph structure}} + \Delta_{\text{interaktioner}}$$

Detta kan analyseras med parade skillnader över dataset, noise levels och seeds, med konfidensintervall och effektstorlekar. En factorial design kan användas i en utökad studie.

Vad skulle ett positivt resultat betyda?

Om G1 $\gg$ A1 och G3: evidens för att fysisk graph topology / relational inductive bias i sig förbättrar symbolic discovery.

Om G1 $\approx$ A1: förbättringen kommer sannolikt huvudsakligen från neural representation/denoising, inte från grafen.

Om G1 $\gg$ G2: clean simulated prior är en viktig del av den rapporterade robustheten. Det begränsar direkt generalisering till verklig okänd fysik.

Om G2 fortfarande $\gg$ T0: starkare evidens för att grafassisterad SR kan fungera på verkliga noisy observations utan tillgång till clean ground truth.

Potentiellt huvudbidrag. Studien skulle gå från ett performance-claim - "GNN+SR fungerar bättre" - till en mekanistisk förklaring av *varför*, *när* och *vilken del* av grafrepresentationen som skapar vinsten.

Praktisk första fas

1. Få originalkod, data, exakta graph-construction-parametrar och SR-konfigurationer från författarna.
2. Reproducera T0 och G1 på samma tio dataset.
3. Implementera G2, A1, G3 och G4 utan att ändra övriga experimentparametrar.
4. Kör först SINDy + PySR. Utöka därefter till samtliga tio SR-metoder om effekten kvarstår.
5. Publicera full seed-logg, configs och data-generation för strikt reproducerbarhet.

Referens

[1] Lazebnik, T. & Liberzon, A. *Moving from table to graph in physics-informed spatio-temporal symbolic regression*. Scientific Reports 16, 16016 (2026). DOI: 10.1038/s41598-026-53882-w. Publicerad 23 maj 2026.